Ingeniería en Desarrollo y

Gestión de Software

Asignatura: Recursamiento 2026 - Extracción de Conocimiento en Bases de Datos

Tema: Actividad de Evaluación 1 – Exploración, clasificación y diagnóstico del conjunto de datos

Unidad 2

Alumno: José Gamaliel Potenciano Méndez

Matrícula: 23301258

Grupo: 10IDGS - G1

Docente: Ing. Jose Luis Herrera Gallardo

Periodo: Septiembre-Diciembre 2026

1. Identificación del dataset

Nombre del proyecto: Análisis y predicción de calidad del aire.

Dataset: Air Quality. **Fuente:** UCI Machine Learning Repository. **Formato:** CSV y XLSX. **Archivo original:** data/raw/air+quality/AirQualityUCI.csv y AirQualityUCI.xlsx.

El conjunto contiene registros horarios de contaminantes, respuestas de instrumentos y condiciones ambientales. La lectura del CSV presenta 9,471 filas físicas y 15 variables; algunas filas finales son espacios sin medición. La ficha de UCI anuncia aproximadamente 9,358 registros y 15 características. El original se conserva sin cambios.

2. Carga y exploración inicial

El notebook ejecuta y explica `df.head()`, `df.shape`, `df.columns`, `df.info()`, `df.dtypes` y `df.describe()`. Estas instrucciones permiten comprobar las primeras filas, la dimensión, los nombres, los tipos y los resúmenes estadísticos.

Date y Time se cargan como texto; las mediciones se cargan como valores numéricos. La conversión de fecha-hora y cualquier tratamiento de faltantes quedan para la siguiente etapa de preparación.

3. Diccionario de datos

Variable	Descripción	Tipo Python	Tipo	Unidad	Utilidad
Date	Fecha del registro	object	Temporal	Fecha	Ordenar
Time	Hora del registro	object	Temporal	Hora	Ordenar
CO(GT)	CO de referencia	float64	Cuantitativa continua	mg/m³	Objetivo de regresión
PT08.S1(CO)	Respuesta sensor CO	int64	Cuantitativa continua	Señal	Entrada candidata
NMHC(GT)	NMHC de referencia	float64	Cuantitativa continua	µg/m³	Contexto
C6H6(GT)	Benceno de referencia	float64	Cuantitativa continua	µg/m³	Contexto
PT08.S2(NMHC)	Respuesta sensor NMHC	int64	Cuantitativa continua	Señal	Entrada candidata
NOx(GT)	NOx de referencia	float64	Cuantitativa continua	ppb	Contexto
PT08.S3(NOx)	Respuesta sensor NOx	int64	Cuantitativa continua	Señal	Entrada candidata
NO2(GT)	NO2 de referencia	float64	Cuantitativa continua	µg/m³	Contexto
PT08.S4(NO2)	Respuesta sensor NO2	int64	Cuantitativa continua	Señal	Entrada candidata
PT08.S5(O3)	Respuesta sensor O3	int64	Cuantitativa continua	Señal	Entrada candidata
T	Temperatura	float64	Cuantitativa continua	°C	Entrada ambiental
RH	Humedad relativa	float64	Cuantitativa continua	%	Entrada ambiental
AH	Humedad absoluta	float64	Cuantitativa continua	No especificada	Entrada ambiental

4. Tipo y fuente de los datos

La fuente es UCI Machine Learning Repository. Son datos estructurados, tabulares y generados principalmente por instrumentos y sensores, con mediciones de referencia y marcas de tiempo. El archivo no corresponde a transacciones, redes sociales ni datos biométricos.

Universidad Tecnológica de TULA-TEPEJI

5. Diagnóstico de calidad

5.1 Valores faltantes

Variable o grupo	Faltantes
CO(GT)	1,797
NOx(GT)	1,753
NO2(GT)	1,756
NMHC(GT)	8,557
PT08.S1, C6H6, PT08.S2, PT08.S3, PT08.S4, PT08.S5, T, RH, AH	480 cada una
Date y Time	114 cada una

UCI documenta `-200` como marcador de faltante. No se sustituyó ni eliminó durante esta actividad. En una etapa posterior se tratará en una copia.

5.2 Registros duplicados

El notebook calcula `df.duplicated().sum()` y deja visible el resultado. Los duplicados se revisarían por fecha y hora antes de decidir si corresponden a una repetición real o a un problema de captura. No se eliminaron.

5.3 Inconsistencias y valores extremos

Se revisan valores negativos distintos de `-200`, fechas y horas que no puedan interpretarse, rangos y valores extremos. Los valores alejados del centro se consideran candidatos a atípicos, no errores automáticos; podrían representar episodios reales o lecturas instrumentales que deben verificarse.

6. Análisis estadístico inicial

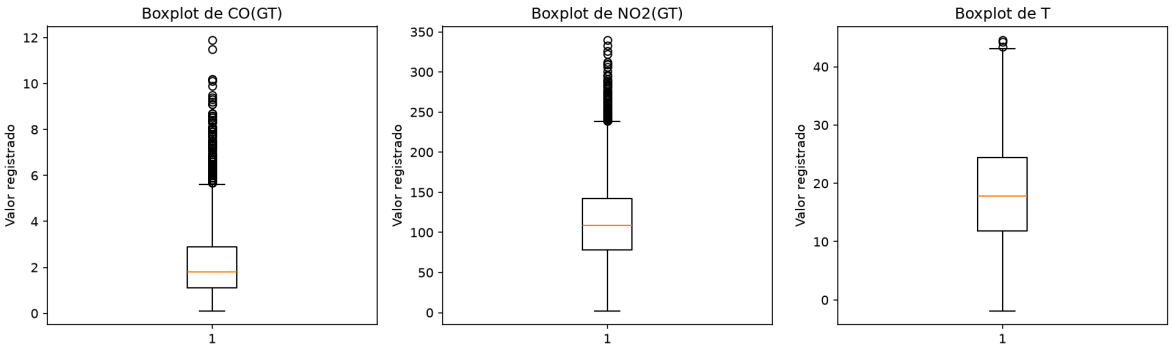
Variable	Media	Mediana	Mínimo	Máximo	Desv. estándar
CO(GT)	2.153	1.800	0.100	11.900	1.453
NO2(GT)	113.091	109.000	2.000	340.000	48.370
T	18.318	17.800	-1.900	44.600	8.832
RH	49.234	49.600	9.200	88.700	17.317
AH	1.026	0.995	0.185	2.231	0.404

La media y mediana permiten comparar el centro de los datos. Los rangos muestran la variación de contaminantes y ambiente; no se interpretan como límites sanitarios.

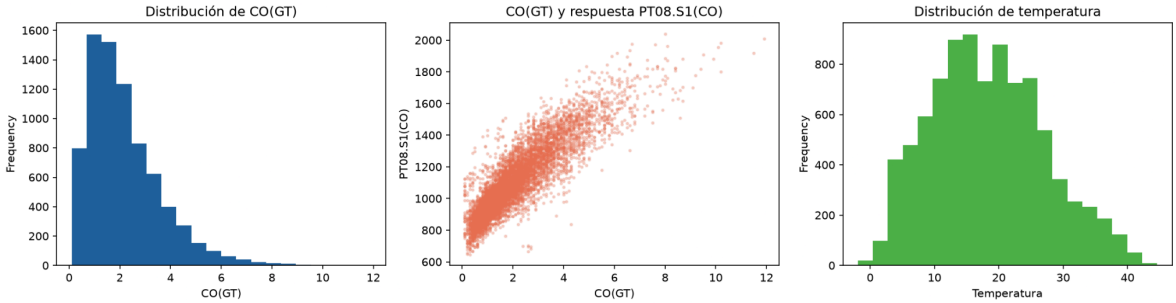
7. Detección inicial de valores atípicos

El notebook genera boxplots para CO(GT), NO2(GT) y T. Las observaciones alejadas del rango central se reportan como candidatas a atípicos. No se eliminan en esta actividad porque la guía solicita diagnóstico antes de limpiar.

Universidad Tecnológica de TULA-TEPEJI



Boxplots de variables numéricas seleccionadas



Histogramas y relación exploratoria

8. Visualización inicial

Se incluyen histogramas de CO y temperatura y una gráfica de dispersión entre CO(GT) y PT08.S1(CO). Cada gráfica incluye título, ejes e interpretación en el notebook. La dispersión sirve para explorar una relación; no demuestra causalidad.

9. Preparación para análisis posteriores

Regresión: CO(GT) como objetivo numérico; PT08.S1(CO), PT08.S2(NMHC), PT08.S3(NOx), PT08.S4(NO2), PT08.S5(O3), T, RH y AH como entradas candidatas.
Clasificación: una variable derivada de CO(GT) con bandas académicas baja, media y alta.
Agrupamiento: las cinco respuestas PT08 junto con T, RH y AH para buscar patrones de comportamiento.

10. Conclusión del diagnóstico

El dataset contiene mediciones horarias de contaminantes, señales instrumentales y ambiente. Es adecuado para continuar con el Proyecto Integrador, pero requiere tratamiento posterior por los faltantes `-200`, posibles duplicados, validación de fechas y horas y revisión de valores extremos. No se modificó el original. El notebook contiene el código, resultados, tablas, visualizaciones, interpretaciones y propuestas solicitadas.

Entrega y repositorio

Notebook ejecutable: notebooks/PotencianoMendez_JoseGamaliel_U2_AE1_Exploracion.ipynb
Informe editable: docs/PotencianoMendez_JoseGamaliel_U2_AE1_Diagnostico.docx
Repositorio:
https://github.com/JoseGamalielP/REC_ECBD_2026_PotencianoMendez_JoseGamaliel

Universidad Tecnológica de
TULA-TEPEJI



Elaborado por: José Gamaliel Potenciano Méndez
Para: Universidad Tecnológica de Tula-Tepeji

Derechos exclusivos de autoría y edición reservados para la Universidad Tecnológica de Tula – Tepeji. Queda prohibida la reproducción total o parcial del contenido de este documento, por cualquier medio o procedimiento, así como su distribución, para otros fines ajenos a los definidos por la propia Universidad Tecnológica de Tula – Tepeji.